

# 基于压缩感知的自适应卡尔曼滤波

郭文彬 李 航

(北京邮电大学泛网无线通信教育部重点实验室, 北京 100876)

**摘 要:** 针对稀疏流信号, 提出了一种自适应卡尔曼滤波恢复方法, 该算法基于压缩感知 AIC 结构, 用有限长的窗口对信号进行观测, 利用前后窗内信号之间的相关性, 建立信号的状态转移方程, 并与压缩感知获得的观测方程共同构成信号的状态空间模型, 进而利用降阶的卡尔曼滤波算法近似得到信号的最小均方误差估计。信号重构阶段通过卡尔曼滤波迭代逐渐得到精确的支撑集, 与以往仅用起始阶段的恢复结果获得支撑集的方法相比, 本算法对起始阶段恢复支撑集的算法的精确程度要求不高, 从而降低了整个算法的复杂度和要求的观测维度。仿真结果显示, 这种自适应的卡尔曼滤波算法在宽带流信号的恢复中可以有效地降低所需观测维度, 且最终结果可近似地收敛到信号的最小均方误差估计。

**关键词:** 压缩感知; 流信号; 卡尔曼滤波

**中图分类号:** TN911    **文献标识码:** A    **文章编号:** 1003-0530(2012)06-0799-07

## Adaptive Kalman Filter based on Compressed Sensing

GUO Wen-bin LI Hang

(Wireless Signal Processing and Network lab, Key Laboratory of Universal Wireless Communications,  
Ministry of Education, Beijing University of Posts and Telecommunications, Beijing 100876, China)

**Abstract:** In this paper, we propose an adaptive Kalman filter based on compressed sensing for the reconstruction of streaming signals. The Analog Information Converter (AIC) structure is implemented for streaming compressive sampling while the signal is observed from a sliding window of finite length. Then we use the correlations between the signals of two continuous windows to model the process in the state-space form so that the Kalman Filter can be implemented to obtain the MMSE estimation of the streaming signals. A simple algorithm with low complexity is proposed to estimate the support at the beginning of every recursion and the estimation that will be refined during the whole operation. As such, the proposed method doesn't need an accurate initial estimation which always demands more observations and higher complexity. The simulation results show that the proposed adaptive Kalman filter can greatly reduce the observation dimensions based on compressed sensing and converge to the ideal Kalman filter with low complexity.

**Key words:** compressed sensing; streaming signals; Kalman filter

## 1 引言

压缩感知理论<sup>[1-2]</sup>近年来已经成为了处理稀疏信号或可压缩信号的重要手段。传统的奈奎斯特采样定理在当前的很多实际应用中(例如:超宽带通信,超宽带信号处理,核磁共振等)要求有非常高的采样率,伴

随着高采样率随之而来的就是高成本,甚至一些过高的采样率无法从技术上实现。而压缩感知的出现给解决这些问题带来了希望—在压缩感知理论中,信号的采样速率不取决于信号的带宽,而是决定于信息在信号中的位置和内容,在采样的同时即对信号数据进行适当压缩。压缩感知理论突破了传统奈奎斯特采样定

收稿日期: 2012-01-04; 修回日期: 2012-05-15

基金项目: NSFC-广东联合自然科学基金(U1035001); 国家重大专项 2012ZX03003006; 国家“973”项目 2009CB320400; 教育部重要高校科研基金 BUPT2009CR0107

理对采样速率的限制,这使其在宽带信号处理领域有着突出的优点和广阔的应用前景。

压缩感知理论证明了当信号在某一变换域上具有稀疏特性时,可以以低于奈奎斯特采样率的速率对其进行采样并高概率地重构。文献[3,4,5]解决了压缩感知理论的硬件实现问题。在文献[3]中,作者提出的 AIC 结构可以直接对模拟连续时间信号进行压缩采样获得低维的观测向量。

现有的压缩感知恢复算法主要针对于有限维信号的重构,对于实际应用中常见的时域流信号,一般采用把信号分成很多有限维的块,再用已有的恢复算法对每帧信号分别进行重构。然而这种对彼此独立的块信号进行恢复的方法会引入很大的块效应,且输入输出延时较大,针对这个问题,文献[6,7]提出了基于 AIC 结构的稀疏流信号恢复方法 SGP,利用 AIC 结构以低于奈奎斯特速率的采样率对信号进行采样,并使用有限长度的观测窗对信号进行观测,由于每次窗口滑动长度相对于窗口长度较小,前后窗口内的信号具有比较大的重复性,因此可认为信号的稀疏结构较少发生突变。SGP 避免了处理不相交的块信号,从而有效地减小了块效应并保证了恢复的实时性<sup>[6]</sup>。

相比于对每一帧信号独立地用非线性优化算法(如 BP)或匹配追踪算法(如 OMP)进行重构,用 SGP 算法恢复稀疏的流信号时在每一次迭代中利用了上一次迭代结果的残差信息以优化支撑集的估计,使恢复结果逐渐收敛到已知稀疏位置时的最小二乘恢复结果,也就是通过逐次迭代得到精确的支撑集,从而把非线性估计转化成了线性估计,显然此时的恢复结果是优于对每帧信号单独使用非线性恢复算法的。这里,稀疏信号的支撑集表示信号非零元素位置构成的集合;支撑集的大小表示非零元素的个数。

然而上述方法仅利用了信号的观测信息,最终获得近似最小二乘估计量。针对流信号帧与帧之间具有很大相关性的特点,我们考虑能否最大程度利用信号之间隐藏的信息从而获得更好的恢复结果。

在线性估计里,卡尔曼滤波可以获得信号的最小均方误差估计量<sup>[8]</sup>。本文提出了一种利用卡尔曼滤波恢复稀疏流信号的机制,利用前后窗口内信号的关联性以建立信号的状态转移方程,和已有的观测方程一起构成信号的状态空间模型,从而利用卡尔曼滤波算

法对信号进行恢复,以获得信号的最小均方误差估计。

用降阶的卡尔曼滤波器恢复稀疏信号的想法最早由 Namrata Vaswani 提出,她在文献[9,10]中用结合了 Dantzig Selector 算法的降阶卡尔曼滤波器恢复时域稀疏的随机游走信号,获得了优于每帧分别使用 Dantzig Selector 进行恢复的结果。上述算法在处理滤波误差时使用非线性优化算法估计支撑集,使算法的复杂度较高;并且恢复效果很强地依赖于 Dantzig Selector 的计算结果,当信噪比较低时,Dantzig Selector 无法获得精确的支撑序列,这会导致后续的卡尔曼滤波误差很大。除此之外,上述文章仅用随机游走信号对性能进行验证,并没有给出算法应用于实际场景时的建模方法。本文针对稀疏流信号前后窗口间的相关性,给出了建立流信号状态空间模型的方法,使卡尔曼滤波可以广泛地应用于实际场景中。此外,提出了一种自适应的卡尔曼滤波算法,利用卡尔曼滤波时域收敛的特性通过迭代使估测得到的支撑集逐渐准确,最终使结果收敛于信号的最小均方误差估计即已知支撑集时理想的卡尔曼滤波恢复结果。该算法减小了对非线性恢复支撑集精确度的依赖程度,并有效地降低了算法的复杂度。

本文提出的针对稀疏流信号建立频域上的状态空间模型并引入卡尔曼滤波器对其进行跟踪恢复的方法,可有效应用于认知无线电、软件无线电场景下的实时频谱分析<sup>[11]</sup>,实现了宽带条件下,稀疏频谱的实时检测和监视,且对信噪比和观测维度的要求较低,在稀疏宽带信号分析方面具有良好的应用前景。

## 2 稀疏流信号的状态空间模型

### 2.1 基于 AIC 的流信号压缩感知

压缩感知理论证明了当信号在某个变换域上具有稀疏性时,可以通过较少次数的线性测量进行采样和重构。用  $x \in R^N$  表示待测的时域宽带信号,压缩感知采样过程可以表示为  $y = Ax$ ,其中  $y$  为观测向量,  $A$  是一个  $M \times N$  的测量矩阵,且有  $M \ll N$ 。信号  $x$  在某一变换域(如频域)上是  $K$  稀疏的,即  $x$  在该变换域上的投影只含有  $K$  个非零系数。若测量矩阵  $A$  满足 RIP 性质,那么信号可以通过求解凸优化问题进行精确地重构。

AIC 结构是压缩感知理论较为完善的硬件实现方式,如图 1 所示,某一时间帧内,连续时域信号  $x(t)$  经

过伪随机序列  $p(t)$  (伯努利序列) 的调制, 得到  $x(t) \cdot p(t)$  经过积分器再以低于奈奎斯特采样率的速率进行采样获得观测向量  $y$ 。




图 1 AIC 结构图

Fig. 1 the AIC structure

对于无限长的流信号  $x$ , 用  $x_n$  表示以奈奎斯特速率采样得到的离散序列, 测量过程可表示为:  $y_m = \sum_n x_n a_{m,n} = \langle x, a_m \rangle$ ,  $y_m$  表示得到的观测向量,  $a_m$  是无限维测量矩阵的行向量, 使用有限长的观测窗对信号  $x_n$  进行观测, 窗口长度为  $N = MR$ , 则系统可等效为在单位时间输入速率为  $N$  输出速率 (测量速率) 为  $M = N/R$  的测量系统, 这里  $R$  表示下采样率, 为简便起见, 本文中的  $R$  都取正整数。此时, 无限维的测量矩阵可等效为  $M \times N$  维的测量矩阵, 且随窗口滑动, 测量矩阵的值不断更新<sup>[6]</sup>。因此, 系统第  $k$  个窗内的信号及相应的测量矩阵和观测向量可表示为:

$$x^k = [x_{kR}, \dots, x_{kR+N-1}]^T \quad (1)$$

$$y^k = [y_k, \dots, y_{k+M-1}]^T \quad (2)$$

$$A^k = \begin{pmatrix} a_{k, kR} & \dots & a_{k, kR+N-1} \\ \vdots & \ddots & \vdots \\ a_{k+M-1, kR} & \dots & a_{k+M-1, kR+N-1} \end{pmatrix} \quad (3)$$

下一时刻, 窗口滑动后, 窗内信号为:

$$x^{k+1} = [x_{kR+R}, \dots, x_{kR+N-1}, x_{kR+N}, \dots, x_{kR+N+R-1}]^T \quad (4)$$

$$y^{k+1} = [y_{k+1}, \dots, y_{k+M}]^T \quad (5)$$

$$A^{k+1} = \begin{pmatrix} a_{k+1, (k+1)R} & \dots & a_{k+1, (k+1)R+N-1} \\ \vdots & \ddots & \vdots \\ a_{k+M, (k+1)R} & \dots & a_{k+M, (k+1)R+N-1} \end{pmatrix} \quad (6)$$

在  $N$  长的窗内, 信号是稀疏的, 以频域稀疏为例, 用  $X = FX$  表示宽带信号稀疏的频谱,  $F$  为  $N \times N$  维 DFT 正变换矩阵。文献 [3] 证明了  $N$  长的观测窗对应的 AIC 观测矩阵高概率地满足 RIP 性质, 只要观测长度满足  $M = O(K \log(N/K))$ 。

因此, 以 AIC 结构为基础的流信号观测方程可表

示为:  $y_k = A_k x_k + n = A_k F^{-1} X_k + n$ 。  $n$  是方差为  $\sigma_{obs}^2$  的高斯白噪声。

## 2.2 信号的状态转移方程

考虑利用窗口滑动前后窗内信号的相关性建立信号的状态转移方程。

已知时域信号的 Z 变换可以表示为:

$$X(z) = \sum_{n=0}^{+\infty} x_n z^{-n} \quad (7)$$

则在长度为  $N$  的窗口内进行观测, 得到第  $k$  帧信号的 Z 变换可以表示为:

$$X_k(z, N) = \sum_{n=k}^{k+N-1} x_n z^{-(n-k)} = z^k \sum_{n=k}^{k+N-1} x_n z^{-n} \quad (8)$$

若每次相对于  $x_n$  滑动一个单位长度, 则窗口滑动后, 第  $k+1$  帧信号可表示为:

$$\begin{aligned} X_{k+1}(z, N) &= z^{k+1} \sum_{n=k+1}^{k+1+N-1} x_n z^{-n} \\ &= z^{k+1} \left( \sum_{n=k}^{k+N-1} x_n z^{-n} - x_k z^{-k} + x_{k+N} z^{-(k+N)} \right) \\ &= z X_k(z, N) - z x_k + z^{-N+1} x_{k+N} \end{aligned} \quad (9)$$

则有  $X_{k+1}(z, N) - z X_k(z, N) = z(e^{-j\omega} x_{k+N} - x_k) = z \nu_k$

将信号变换到频域后, 可表示为:

$$\begin{aligned} X_{k+1}(e^{j\omega}, N) - e^{j\omega} X_k(e^{j\omega}, N) &= e^{j\omega} \nu_k \\ &= e^{j\omega} (e^{-jN\omega} x_{k+N} - x_k) \end{aligned} \quad (10)$$

即前后滑动窗之间的关系与滑入和滑出窗口的值的差有关, 当窗口大小合适时, 则可能值很小。

令  $\omega = 2\pi m/N$ , 则有

$$\begin{aligned} X_{k+1} \left( e^{j \frac{2\pi m}{N}}, N \right) &= \sum_{n=0}^{N-1} x_{n+k+1} e^{-j \frac{2\pi mn}{N}} \\ &= e^{j \frac{2\pi m}{N}} X_k \left( e^{j \frac{2\pi m}{N}}, N \right) + e^{j \frac{2\pi m}{N}} (x_{k+N} - x_k) \end{aligned} \quad (11)$$

其中  $m = 0, 1, 2, \dots, N-1$ 。

将信号扩展为矢量形式后得到:

$$\begin{aligned} X_{k+1} &= \text{Diag} \left( 1, e^{j \frac{2\pi}{N}}, \dots, e^{j \frac{2\pi}{N} (N-1)} \right) X_k \\ &\quad + \begin{pmatrix} 1 \\ e^{j \frac{2\pi}{N}} \\ \vdots \\ e^{j \frac{2\pi}{N} (N-1)} \end{pmatrix}^T (x_{k+N} - x_k) \end{aligned} \quad (12)$$

为表示简便, 我们令  $D = \text{Diag} \left( 1, e^{j \frac{2\pi}{N}}, \dots, e^{j \frac{2\pi}{N} (N-1)} \right)$ ,

在下采样率为  $R$  的系统中,窗口每次滑动  $R$  个单位长度,则有

$$\begin{aligned} \mathbf{X}_{k+R} &= \mathbf{D}^R \mathbf{X}_k + (\mathbf{w}_0, \mathbf{w}_1, \dots, \mathbf{w}_{R-1}) \begin{pmatrix} x_{N+k+R-1} - x_{k+R-1} \\ x_{N+k+R-2} - x_{k+R-2} \\ \vdots \\ x_{N+k} - x_k \end{pmatrix} \\ &= \mathbf{D}^R \mathbf{X}_k + \sum_{m=0}^{R-1} \mathbf{w}_m (x_{N+k+R-1-m} - x_{k+R-1-m}) \end{aligned} \quad (13)$$

$$\text{其中 } \mathbf{w}_m = \left( 1, e^{j\frac{2\pi}{N}m}, \dots, e^{j\frac{2\pi}{N}m(N-1)} \right)^T.$$

等号右边第二项  $\sum_{m=0}^{R-1} \mathbf{w}_m (x_{N+k+R-1-m} - x_{k+R-1-m})$ , 是滑入滑出窗口的信号差值的加权,当窗口长度合适时,这一项的值可能很小,这点将在仿真结果中得到证明。这里我们把它假设成均值为零的高斯白噪声  $v$ , 方差  $\sigma_{sys}^2$  可由时域信号值确定,因此可由信号的一个样本实现得到估计值,作为系统的先验信息<sup>[9]</sup>。由此,我们得到基于 AIC 结构的流信号状态空间模型为:

$$y_k = A_k x_k + n = A_k F^{-1} X_k + n = H_k X_k + n \quad (14)$$

$$\mathbf{X}_{k+R} = \mathbf{D}^R \mathbf{X}_k + v = \Phi \mathbf{X}_k + v \quad (15)$$

### 3 基于压缩感知的自适应卡尔曼滤波算法

在上一部分中,我们利用窗口滑动前后信号的相关性建立了基于 AIC 结构的流信号状态空间模型,这里我们利用降阶的卡尔曼滤波器对信号进行实时的重构。假设信号  $x$  在频域内稀疏度为  $K$ ,首先用观测向量与恢复矩阵求相关,得到相关度最大的位置估计支撑集,则重构问题转化成了低维的线性恢复问题,利用降阶的卡尔曼滤波器对信号进行恢复。窗口滑动后,对滤波误差同样适用求相关的方法得到残差里可能是支撑序列的位置与之前估测的支撑序列取并集,作为下一帧信号的支撑集进行卡尔曼滤波。由于求相关的方法只能得到支撑集的粗略估计,对于每一帧信号,前一帧信号的  $K$  个最大值的位置以及前一帧信号残差中与恢复矩阵相关性最大的  $K$  个位置都可能包含支撑集的真实元素,因此取这两个集合的并集即  $2K$  个元素构成的集合,对相应的位置进行卡尔曼滤波运算,得到稀疏信号的估计。每帧信号输出前,根据先验信息  $K$ ,对信号进行截断,只保留频谱中  $K$  个最大的值作为最终恢复结果。由于卡尔曼滤波的误差时域收敛,因此通过迭代噪声误差将被抑制,得到的支撑集将趋于准确,最

终的恢复结果可以收敛到理想的卡尔曼滤波结果,近似于信号的最小均方误差估计。

基于压缩感知的自适应卡尔曼滤波算法实现步骤如下:

1) 令恢复矩阵  $H_k = A_k F^{-1}$ , 计算上帧信号的残差  $r = y - HX$ , (初始残差  $r_1 = y_1$ ), 计算残差与恢复矩阵列的相关度  $p = (A F^{-1})^* r$ , 得到  $K$  个相关度最大的位置作为支撑集,与上帧信号得到的支撑集(初始时刻为空集)求并集,作为估计的支撑集  $T$ 。

2) 使用降阶卡尔曼滤波器对信号进行恢复,算法如下:

$$P_{k+1|k} = \Phi P_{k|k} \Phi^T + Q \quad (16)$$

$$K_{k+1} = P_{k+1|k} H_k^T [H_k P_{k+1|k} H_k^T + R]^{-1} \quad (17)$$

$$P_{k+1|k+1} = [I_n - K_{k+1} H_k] P_{k+1|k} \quad (18)$$

$$X_{k+1|k} = \Phi X_{k|k} \quad (19)$$

$$X_{k+1|k+1} = X_{k+1|k} + K_{k+1} (y_{k+1} - H_k X_{k+1|k}) \quad (20)$$

$R, Q$  分别为观测噪声和系统噪声的方差阵。该降阶的卡尔曼滤波仅工作在由支撑集内元素确定的维度上。

3) 取恢复得到的  $\hat{X}$  中  $K$  个最大的值最为最终结果  $X$  输出,对应位置作为本帧信号恢复的支撑集,返回步骤一进行迭代。

算法不依赖于支撑集的一次恢复精度,而是通过迭代使恢复的支撑集逐渐趋于准确,从而使滤波结果逐渐收敛到理想的卡尔曼滤波结果,因此不需要使用精度高但复杂度也高的算法(如 Dantzig Selector)恢复支撑集。算法相比于文献[9,10]中的 KFCS 算法可能收敛速度较慢,但 KFCS 算法很强烈地依赖于 Dantzig Selector 的恢复结果,当信噪比较低时,若无法得到较为精确的支撑集,后续卡尔曼滤波结果将无法收敛到理想的卡尔曼滤波结果。相对于 SGP 算法中使用最小二乘法对信号进行恢复,本算法中使用卡尔曼滤波的好处在于保持稀疏度不变时可以有效地降低观测维度  $M$ ,仍能使结果收敛于理想的卡尔曼滤波结果,而信号的最小二乘估计不具有时域收敛特性,无法通过迭代进一步降低误差从而从残差中恢复新的支撑点,因此对观测维度要求相对较高。

### 4 算法仿真

定义信噪比  $SNR$  为每一帧内信号与噪声能量的比值,仿真采用频域稀疏的宽带信号,在频谱内任选  $K$

个值作为中心频率产生升余弦信号,对应位置即为支撑集。对信号进行采样时,AIC 结构的下采样率为  $R$ ,观测维度为  $M$ ,则窗口长度  $N=MR$ 。与 SGP、KFCS 等假设条件相同,仿真时假设信号的稀疏度  $K$  已知,由于窗口是缓慢滑动的,相邻窗口内信号的相关性很大,因此我们可以认为信号的稀疏模式在一段时间内保持不变<sup>[6]</sup>。观测噪声方差作为先验信息已知。对于系统噪声方差,由于它可由时域信号值直接确定,因此可由信号的一次实现估计得到,作为先验信息<sup>[8]</sup>。

首先固定观测维度  $M=100$ ,稀疏度  $K=10$ ,信噪比  $SNR=30\text{dB}$ ,改变下采样率  $R$  的值,则窗口大小随  $R$  发生改变。此时的观测数满足 RIP 性质的要求即  $M \geq O(K \log(N/K))$ ;信噪比足够大可认为噪声对结果的干扰非常小。采用不同的大小的窗口对卡尔曼滤波进行仿真,得到窗口大小对算法的影响。

仿真结果如图 2 所示,对不同的  $N$ ,恢复结果 MSE 很小且时域收敛,由此证明第二部分中构造的信号的状态空间模型是可行的。仿真结果显示,在观测维度固定且足够的情况下,改变窗口大小对收敛速度略有影响但不大。





图2 不同窗口下的卡尔曼滤波恢复结果

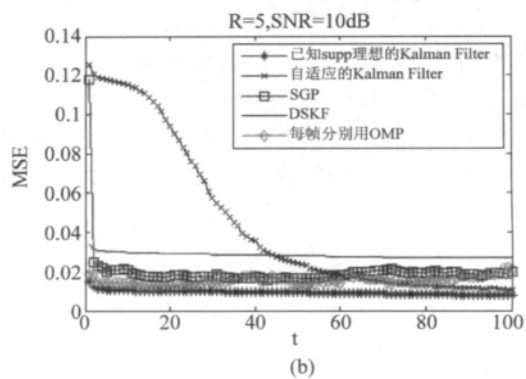
Fig.2 simulation results of different windows



(a)

保持频谱分辨率不变(即  $N$  不变),稀疏度不变,变化不同的  $SNR$  和  $R$  值对算法性能进行仿真,并与理想的卡尔曼滤波、SGP、KFCS 以及每帧分别使用 OMP 算法进行比较。

为保证频谱分辨率一定,固定窗口长度为  $N=500$ ,下采样率  $R$  分别取 5,10,20,即对应的观测维度分别为 100,50,25。分别在低信噪比 10dB 和高信噪比 15dB 两种场景下仿真。仿真结果如图 3 所示,结果显示,当信噪比较高,下采样率较小时,如图(a)所示,自适应卡尔曼滤波、SGP、DSKF(即文献[9,10]中的 KFCS)和 OMP 都可以获得比较好的恢复结果,近似于理想的卡尔曼滤波结果。对于同样的  $R=5$ ,观测维度足够大,当信噪比降低时(见图(b)),DSKF 算法由于在 Dantzig Selector 恢复阶段无法获得精确的支撑集信息,后续的误差较大,无法收敛到理想的卡尔曼滤波结果。SGP 和 OMP 的误差也略有增大,自适应卡尔曼滤波收敛速度变慢,但最终仍可收敛到理想的卡尔曼滤波结果。增大下采样率  $R$  以后,即降低了观测维度,此时的观测矩阵可能不再严格地满足 RIP 性质,因此非线性恢复支撑集的效果会变差,导致 SGP、DSKF、OMP 的恢复精度大大降低(见图 c、d、e、f),自适应卡尔曼滤波起始误差也相应变大,收敛速度减慢,但经过多次迭代后,由于卡尔曼滤波的时域收敛特性,最终可以从残差中恢复出准确的支撑点,从而使支撑集逐渐趋于准确,结果仍可收敛到理想的卡尔曼滤波结果。仿真结果显示,在观测维度较低或信噪比较低的情况下,SGP 即 DSKF 算法都无法使恢复结果收敛到理想的卡尔曼滤波结果,此时自适应卡尔曼滤波算法可以通过迭代最终收敛,也即以牺牲收敛速度为代价最终获得较为理想的恢复结果,同时保持了较低的算法复杂度。



(b)

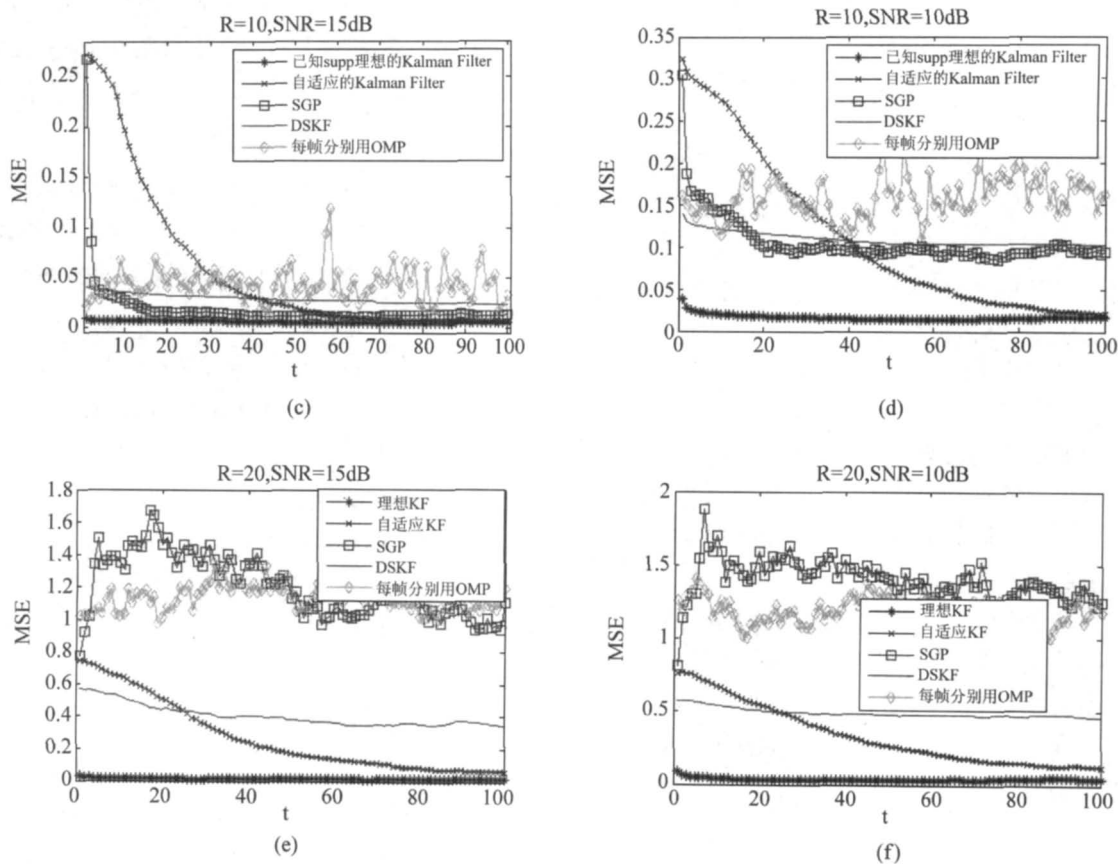


图3 自适应卡尔曼滤波与其他算法性能比较

Fig. 3 simulation results of different algorithms

## 5 结论

本文分析了基于 AIC 结构的稀疏流信号的恢复方法,推导了建立信号状态空间模型的方法,从而为使用卡尔曼滤波器奠定了基础。在信号重构阶段,提出了自适应的卡尔曼滤波方法,通过求相关值的方法得到粗略的支撑集并用卡尔曼滤波迭代逐渐恢复出精确的支撑集,使滤波结果最终收敛到已知支撑集的理想卡尔曼滤波结果。通过 MATLAB 仿真验证了算法的性能,并与已有的 SGP、KFCS 等方法进行了比较,结果显示自适应的卡尔曼滤波方法在信噪比低且观测维度低时也能通过迭代最终收敛到理想的卡尔曼滤波结果,且算法复杂度与理想的卡尔曼滤波器相当,远低于使用了 Dantzig Selector 的 KFCS 算法。下一步重点研究的内容是,如何使自适应的卡尔曼滤波算法能够更快速地收敛到理想的卡尔曼滤波结果。

## 参考文献

- [1] E. Candès, J. Romberg, and T. Tao. Robust uncertainty principles: Exact signal reconstruction from highly incomplete frequency information [J]. *IEEE Transactions on Information Theory*, 2006, 52(4): 489-509.
- [2] E. Candès. Compressive sampling [C]. *Proceedings of International Congress of Mathematicians 2006*: 1433-1452.
- [3] J. A. Tropp, J. N. Laska, M. F. Duarte, J. K. Romberg, and R. G. Baraniuk. Beyond Nyquist: Efficient sampling of sparse, band limited signals [J]. *IEEE Trans. on Information Theory*, Jan 2010, 56(1): 520-544.
- [4] J. Laska, S. Kirolos, M. Duarte, T. Ragheb, R. Baraniuk, and Y. Massoud. Theory and implementation of an analog-to-information converter using random demodulation [C]//*IEEE International Symposium on Circuits and Systems 2007*: 1959-1962.
- [5] A. Veeraraghavan, D. Reddy, and R. Raskar. Coded strobing photography: Compressive sensing of high-speed periodic events [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2011, 33(4): 671-686.
- [6] P. T. Boufounos and M. S. Asif. Compressive sampling for

- streaming signals with sparse frequency content [C] // Annual Conference on Information Sciences and Systems , March 2010.
- [7] P. T. Boufounos and M. S. Asif. Compressive Sensing for streaming signals using the Streaming Greedy Pursuit [C] // Military Communications Conference , MILCOM , 2010.
- [8] Steven M Kay. Fundamentals of Statistical Signal Processing Volume I: Estimation Theory. Prentice Hall PTR. 1993.
- [9] N. Vaswani. Kalman filtered compressed sensing [C]. // Proceedings of ICIP 2008.
- [10] N. Vaswani. KF-CS: Compressive Sensing on Kalman Filtered Residual [J]. arXiv 2010:0912.1628v3.
- [11] 陈曾平, 吴巨红, 宿绍莹, 郭仕剑. 宽带实时频谱分析技术及其应用[J]. 信号处理 2012 28(2): 151-157.  
Chen Zeng-ping, Wu Ju-hong, Su Shao-ying, Guo shi-jian. The technology and application of wideband real-time

spectrum analysis [J]. Signal Processing. 2012, 28(2): 151-157. (in Chinese)

#### 作者简介



郭文彬(1971-), 男, 福建龙岩人, 2005 年获北京邮电大学工学博士, 北京邮电大学副教授, 硕士生导师。研究方向为: 信号处理, 认知无线电及其关键技术。E-mail: gwb@bupt.edu.cn



李航(1989-), 女, 辽宁铁岭人, 2011 年毕业于北京邮电大学取得学士学位, 现为北京邮电大学信息与通信工程学院在读硕士研究生。主要研究方向为: 压缩感知算法及其应用。E-mail: lihangbupt@gmail.com