

Es ist nicht anschaulich, durch die Abbildungen zu bestimmen, welches Verfahren besser ist. Deswegen vergleichen wir die Ergebnisse aus allen Verfahren quantitativ, wie in der Abbildung 6.5 dargestellt. Wir können sehen, dass unser Verfahren im Vergleich zum rauschfreien Fall relativ unwirksam ist. Aber im rauschbehafteten Fall gibt es noch eine Verbesserung um 25 Prozent im Vergleich zum traditionellen Kalman-Filter. Gleichzeitig können wir sehen, dass der Unterschied zwischen dem rsKF und dem Kalman-Filter in diesem Fall gering ist, weil die Anregung bekannt ist, d. h. selbst wenn es keine Messung an der Spitze gibt, können wir aus dem Systemmodell die Temperaturänderung hier noch erkennen.

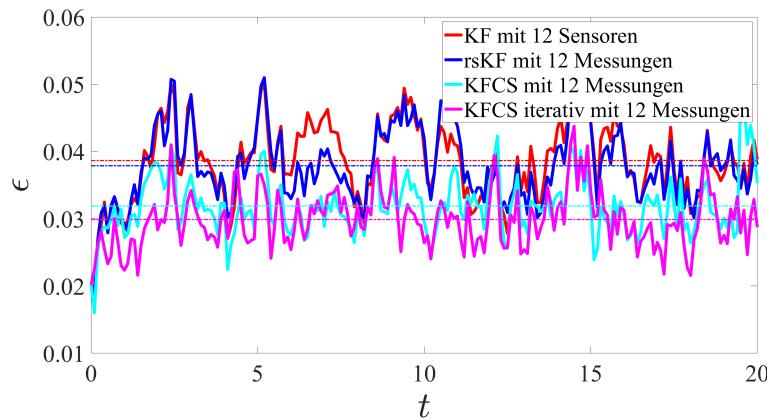


Abbildung 6.5: Vergleich für rauschbehaftetes Signal.

6.2 KFCS für 2D-Signale

In diesem Abschnitt werden wir das 2D-Signal mit dem KF und dem KFCS rekonstruieren.

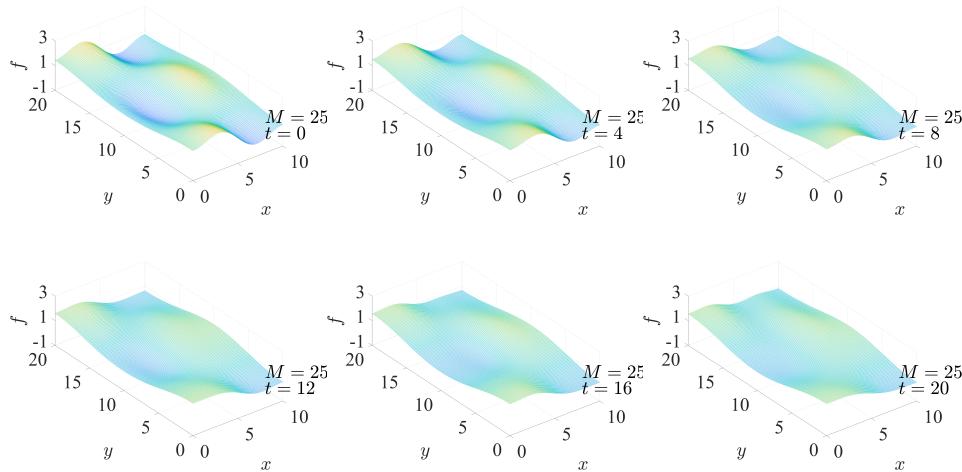


Abbildung 6.6: 2D-Kalman-Filter mit 25 Sensoren.

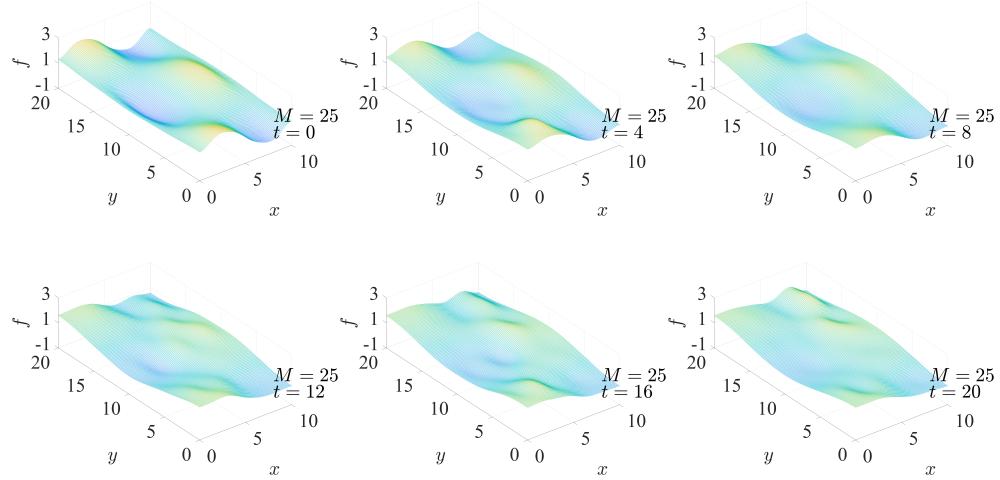


Abbildung 6.7: 2D-KFCS mit 25 Messungen.

Um die Ergebnisse anschaulicher zu vergleichen, haben wir die Abbildung 6.8 erstellt. Wir können aus der Abbildung feststellen, dass KFCS im 2D-Fall bessere Ergebnisse erzielt als das Kalman-Filter, und dass diese Verbesserung etwa 25 Prozent beträgt.

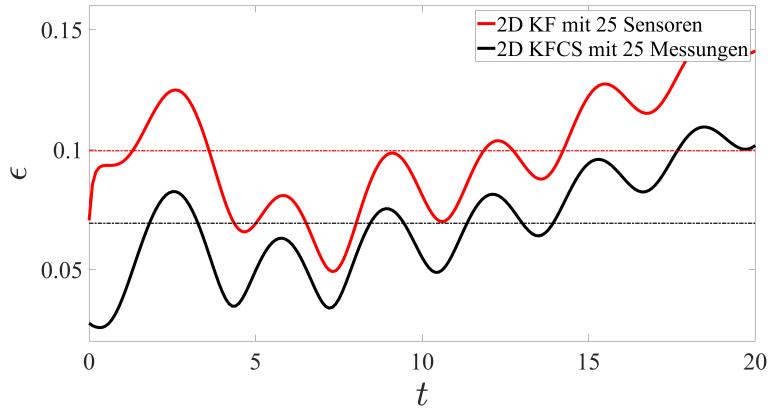


Abbildung 6.8: Vergleich für 2D-Signal.

6.3 Fehlerbewertung

Aus der vorherigen Simulation können wir erkennen, dass die Fehler in verschiedenen Fällen unterschiedlich sind und dass es unterschiedliche Grade gibt, wie gut oder schlecht das KFCS und das Kalman-Filter in verschiedenen Fällen sind. Deswegen werden 10 verschiedene Systemrauschen und 10 verschiedene Messunsicherheiten ausgewählt. Dann kombinieren wir sie und bekommen wir 100 verschiedene Kombinationen. Für jede Kombination werden 300 Simulationen durchgeführt, wobei das Signal mit dem Kalman-Filter bzw. dem KFCS rekonstruiert wird und die Fehler berechnet werden. Das Ergebnis wird in den folgenden Abbildungen gezeigt.

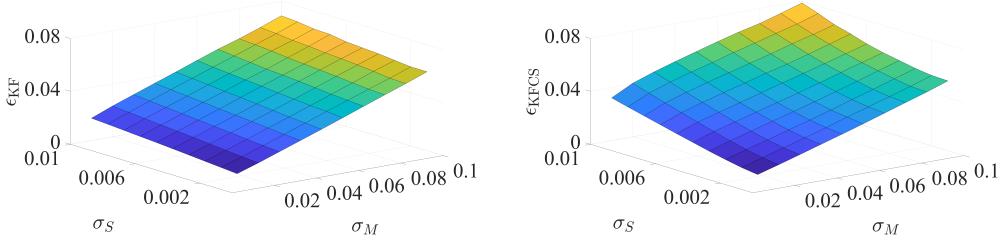


Abbildung 6.9: Fehler, links: Kalman-Filter, rechts: KFCS.

Um den Unterschied deutlicher zu sehen, haben wir ihre Unterschiede berechnet, also $\Delta\epsilon = \epsilon_{KF} - \epsilon_{KFCS}$. Dann bekommen wir die folgende Abbildung

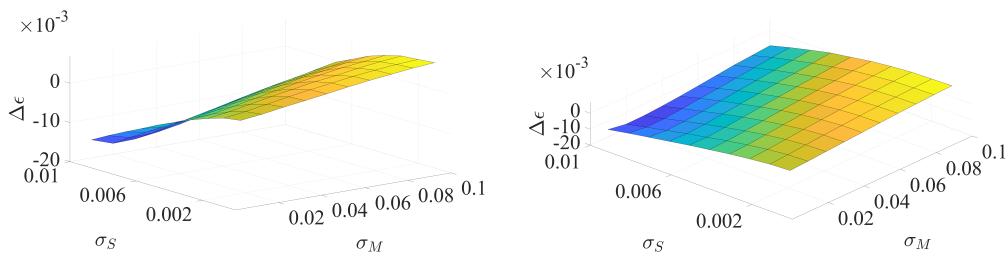


Abbildung 6.10: Differenzfehler von verschiedenen Aspekten.

Aus der Definition können wir wissen, dass das KFCS besser ist als das Kalman-Filter, wenn $\Delta\epsilon$ positiv ist und umgekehrt. So können wir feststellen, dass das Kalman-Filter besser als KFCS ist, wenn das Systemrauschen relativ größer als das Messrauschen ist. Das KFCS ist besser als das Kalman-Filter, wenn das Messrauschen relativ größer als das Systemrauschen ist. Der Grund dafür ist, wenn das Systemrauschen groß ist, ist das Signal nicht mehr dünnbesetzt, d. h. das Vorwissen, dass das Signal dünnbesetzt ist, funktioniert nicht mehr. Und wenn das Systemrauschen sehr groß ist, kann das Compressive-Sensing sogar negative Auswirkung auf der Schätzung machen.

6.4 Zusammenfassung

In diesem Kapitel verwenden wir das Kalman-Filter und das KFCS im rauschbehafteten und 2D-Fall und wir analysieren die Fehler. Wir stellen fest, dass KFCS in diesen Fällen immer noch besser ist als das KF und dass es eine Verbesserung von etwa 25 Prozent gibt. Schließlich führten wir eine Fehlerbewertung von Signalen mit unterschiedlichem Rauschen durch und wir fanden heraus, dass das KFCS deutlich besser als das Kalman-Filter ist, wenn das Messrauschen relativ größer als das Systemrauschen ist. D. h. wenn wir das System genau modellieren können und

Kapitel 6. Erweiterungen des Verfahrens

das Signal mit relativ schlechten Sensoren messen, können wir bessere Ergebnisse erhalten. Dies passt auch zu unserem Ziel, Energie zu sparen.

KAPITEL 7

Zusammenfassung und Ausblick

7.1 Zusammenfassung

In dieser Arbeit haben wir die Wärmeleitung, das Kalman-Filter, das Compressive-Sensing, die Signalanalyse, die Informationsfusion und die Fehlerbewertung untersucht.

In dieser Arbeit wurde die Wirksamkeit des Verfahrens am Beispiel der Wärmeleitung überprüft. Deswegen haben wir zuerst die analytischen und numerischen Lösungen der Temperaturverteilung aus dem Diffusionsmodell hergeleitet und die verschiedenen Fälle simuliert.

Wir haben dann das Kalman-Filter hergeleitet und die Signalschätzung der Temperaturverteilung simuliert. Dann wurde das Compressive-Sensing vorgestellt und das Compressive-Sensing mit den 1D- und 2D-Signalen als Beispiele gezeigt.

In Bezug auf die Signalanalyse hat diese Arbeit die Eigenschaften von Signalen analysiert und drei Methoden vorgeschlagen, die es ermöglichen, das Compressive-Sensing auch auf nicht-dünnbesetzte Signale anzuwenden. Die Methoden sind nämlich dünnbesetzte Änderung, Dimensionreduzierung und Sparse-Coding-Representation.

Bei der Informationsfusion hat die Arbeit zwei Fusionsverfahren vorgeschlagen, Fusion durch die Kalman-Gleichung und durch die Pseudo-Messungen. In den ersten Ansatz ist die Gewichtung in der Praxis schwierig zu bestimmen, deswegen haben wir den zweiten Ansatz vorgeschlagen, also das Verfahren mit Pseudo-Messungen. In diesem Verfahren spielt die Gewichtung weniger Rolle. Darüber hinaus fusionieren wir das Kalman-Filter und das Compressive-Sensing weiter und wir setzen nicht nur das Ergebnis aus dem Compressive-Sensing in das Kalman-Filter ein, sondern wir führen das Ergebnis vom Kalman-Filter auch zu dem Compressive-Sensing zurück, wodurch die Struktur kompakter und vollständiger wird. Diese Arbeit hat dann ein iteratives Verfahren zur Überwindung der Nichtlinearitäten des Problems vorgeschlagen. Schließlich haben wir durch die Simulationen herausgefunden, dass das

neue Verfahren in idealen Fällen eine Verbesserung von etwa 70 Prozent gegenüber dem traditionellen Kalman-Filter bietet.

Schließlich hat diese Arbeit das Verfahren auf rauschbehaftete und 2D-Signale angewendet und festgestellt, dass das neue Verfahren in diesen Fällen eine Verbesserung von 25 Prozent bringt. Um den Zusammenhang zwischen den Rauschen und den Ergebnissen zu untersuchen, wurden in dieser Arbeit 100 verschiedene Kombinationen von Systemrauschen und Messunsicherheiten ausgewählt und 300 Simulationen für jede Kombination durchgeführt, um den durchschnittlichen Fehler zu berechnen. Durch unsere Analyse haben wir festgestellt, dass unser Verfahren deutlich besser ist als das Kalman-Filter, wenn das Systemrauschen relativ gering als die Messunsicherheit ist.

7.2 Ausblick

Die Arbeit ist aber noch nicht perfekt. In der Zukunft kann das Verfahren in folgenden Aspekten noch verbessert werden.

- Adaptive Pseudo-Messungen

In unserem Verfahren waren die Positionen der Pseudo-Messungen fest, z. B. wurden in dieser Arbeit die Pseudo-Messungen an den möglichen Sensorstellen ausgewählt. In zukünftigen Studien kann man versuchen, die Position der Pseudo-Messungen adaptiv zu wählen, z. B. zufällig gewählt und die Wahrscheinlichkeit der Pseudo-Messungen ist proportional zur Unsicherheit. Dadurch wird die Unsicherheit der Gesamtschätzung minimiert.

- Bestimmen der Fehlerverteilung des Compressive-Sensing

In dieser Arbeit wurde der Fehler vom Compressive-Sensing als Gauß'sche Verteilung behandelt. Tatsächlich ist die Fehlerverteilung vom Compressive-Sensing nicht eine Gauß'sche Verteilung, daher ist das Kalman-Filter nicht optimal. Obwohl wir versuchen, die optimale Lösung durch ein iteratives Verfahren zu finden, ist der Rechenaufwand sehr hoch. Daher kann man in der Zukunft die Fehlerverteilung, insbesonders die Kovarianzmatrix, vom Compressive-Sensing untersuchen, dann lässt sich KF besser einsetzen, oder ein besserer Filter entworfen wird, um die optimale Lösung direkt zu finden.